



GeoAI

SMART CITY · AIR QUALITY

GEOAI · SMART CITY · CALIDAD DEL AIRE

Plataforma GeoAI de Calidad del Aire Gran Bilbao

Monitorización, análisis espacial GIS y predicción de calidad del aire con Machine Learning — 7 estaciones, 2015–2026



Arman Ghaziaskari Naeini

GIS & Spatial Data Scientist · Bilbao, España

<https://armanghazi.github.io/portfolio/>

geoai-dashboard.streamlit.app

¿Qué es esta plataforma?

7

Estaciones de medición

4

Contaminantes (PM2.5, PM10, NO₂, SO₂)

12

Años de datos (2015–2026)

~29K

Registros diarios

Cuatro pilares técnicos



Análisis Espacial GIS

Buffers OSM, distancias, terreno (DEM) y transporte de viento
13 notebooks, 35 features espaciales.



Machine Learning

XGBoost para predicción diaria de contaminantes, validado con split temporal estricto.



Dashboard Interactivo

10 páginas en Streamlit — monitoreo, tendencias, pronóstico y soporte a decisiones.



Estándares Múltiples

EAQI/ICA,
guías OMS 2021,
Directiva UE 2008/50/EC
cada uno con su propósito.

Los Cuatro Contaminantes Monitorizados

Cada uno con un origen, tamaño de partícula y comportamiento atmosférico distinto

PM2.5

Partículas finas ($\leq 2.5 \mu\text{m}$)

Tráfico, combustión, industria.
Penetran hasta los pulmones
— el contaminante con mayor
impacto en salud.

PM10

Partículas gruesas ($\leq 10 \mu\text{m}$)

Polvo, obras, erosión, polen.
Comparte fuentes con PM2.5
pero incluye partículas de
origen natural.

NO₂

Dióxido de nitrógeno (gas)

Combustión a alta
temperatura — sobre todo
tráfico rodado. El
contaminante más urbano de
los cuatro.

SO₂

Dióxido de azufre (gas)

Combustión de combustibles
con azufre
— industria pesada y tráfico
marítimo/portuario.

Depuración de Datos — De 10 a 7 Estaciones

Decisión metodológica basada en calidad de datos, no en conveniencia

ANTES

10

estaciones seleccionadas inicialmente

- Cobertura geográfica más amplia
- Algunas con series temporales muy incompletas
- Huecos de missing values no recuperables

DESPUÉS

7

estaciones finales — base de toda la plataforma

- Series temporales completas y consistentes 2015–2026
- Imputación MICE viable solo con cobertura suficiente
- BARAKALDO, BASAURI, ERANDIO, MAZARREDO, MUSKIZ, SANTURCE, ALGORTA

Depuración de Variables — Contaminantes

El mismo criterio de calidad se aplicó a las variables medidas

Eliminados por missing values

CO

Monitoreo discontinuo entre estaciones — cobertura insuficiente tras filtrar las 7 estaciones finales.

O₃

Series con vacíos significativos en múltiples años — no cumplía el umbral mínimo de datos válidos.

Variables finales conservadas

PM_{2.5}


PM₁₀

NO₂

SO₂


Análisis Exploratorio — Series Temporales

Promedio mensual de los 4 contaminantes (2015–2026)



Promedio de Contaminantes por Estación

PM2.5 promedio histórico — ordenado de menor a mayor



Correlación entre Contaminantes

	PM2.5	PM10	NO ₂	SO ₂
PM2.5	1.00	0.78	0.41	0.12
PM10	0.78	1.00	0.35	0.15
NO ₂	0.41	0.35	1.00	0.46
SO ₂	0.12	0.15	0.46	1.00

Lectura del análisis

- PM2.5 ↔ PM10: $r = 0.78$
— fuentes compartidas (tráfico, polvo, obras)
- NO₂ ↔ SO₂: $r = 0.46$
— asociación moderada con combustión e industria
- SO₂ ↔ partículas: correlación casi nula (0.12–0.15)
— origen industrial/portuario distinto
- NO₂ es estructuralmente independiente
— contaminante puramente urbano (tráfico)

Detección de Valores Atípicos (IQR)

Método: rango intercuartílico ($Q1 - 1.5 \times IQR$, $Q3 + 1.5 \times IQR$)

PM_{2.5}

Estaciones con
más outliers:

SANTURCE & BARAKALDO

PM₁₀

Estaciones con
más outliers:

BASAURI & BARAKALDO

SO₂

Estaciones con
más outliers:

MAZARREDO & BARAKALDO

NO₂

Estaciones con
más outliers:


MAZARREDO & ERANDIO



BARAKALDO aparece como estación con outliers en 3 de los 4 contaminantes — consistente con su perfil de mayor densidad de tráfico e industria, confirmado posteriormente por el análisis espacial GIS (densidad de carreteras más alta de la red).

Tendencia a Largo Plazo — Marcador COVID

Promedio anual de contaminantes, 2015–2026



Línea roja en el notebook marca el inicio de COVID (2020) — caída brusca en NO₂ (tráfico), SO₂ sube tras la pandemia, PM2.5 mantiene tendencia descendente estructural.

Red de Monitorización — Gran Bilbao

7 estaciones · 5 zonas ambientales · mapeadas con Folium

 **MAZARREDO**

Urbana

 **ERANDIO**

Urbana

 **BASAURI**

Industrial

 **BARAKALDO**

Industrial

 **SANTURCE**

Puerto

 **ALGORTA**

Costera

 **MUSKIZ**

Refinería



Visualización geoespacial: marcadores Folium + mapas de calor (HeatMap) por contaminante, sobre coordenadas reales de cada estación.

Análisis Espacial GeoAI

4 notebooks — 35 features espaciales por estación

10a

Análisis de Buffers

Densidad de carreteras y uso de suelo (OSM) a 500m/1km/2km

10b

Distancias

Distancia Haversine a puerto, Petronor, AP-8, costa y centro

10c

Terreno (DEM)

Elevación, pendiente y índice de relieve — Copernicus GLO-30

10d

Transporte de Viento

Dirección de viento ERA5 × estación — patrones de dispersión

Hallazgo principal: densidad de carreteras → NO₂, $r = +0.83$ (predictor espacial más fuerte de la red)

La Paradoja de MUSKIZ

Confirmada por tres métodos GIS independientes

34.6%

Mayor porcentaje de uso industrial del suelo en toda la red
(Refinería Petronor)

6.5 $\mu\text{g}/\text{m}^3$

Sin embargo: el PM2.5 más bajo de toda la red
— estación estructuralmente más limpia

¿Por qué?

- ✓ Posición costera — brisa marina del NW dispersa emisiones de Petronor
- ✓ Mayor distancia al centro urbano de toda la red
- ✓ Índice de relieve de terreno (TRI) alto — favorece mezcla turbulenta

Predicción con Machine Learning

XGBoost — predicción del día siguiente, validado en datos 2024–2026

Contaminante	R ²	RMSE	MAE	Interpretación
NO ₂	0.560	5.97	4.43	El mejor — ciclo semanal de tráfico regular
PM2.5	0.479	3.33	2.50	Persistencia + factores meteorológicos
PM10	0.460	6.26	4.45	Eventos de polvo añaden variabilidad
SO ₂	0.390	1.87	1.23	Más difícil — emisiones industriales/portuarias esporádicas

Rigor metodológico

- Split temporal estricto: entrenamiento < 2023, validación 2023, test ≥ 2024 — un split aleatorio infló el R² a 0.84 por data leakage (detectado y corregido)
- 62 features por modelo: meteorología, lags, medias móviles — calculadas en tiempo real, sin necesidad de reentrenar

Tres Estándares, Tres Preguntas Distintas

EAQI/ICA · OMS 2021 · Directiva UE 2008/50/EC — cada uno responde algo diferente



EAQI / ICA

¿Es seguro salir hoy?

Índice europeo de calidad del aire
— comunicación pública diaria.

Umbral calibrado para alertas de corto
plazo (Bueno → Extremadamente malo).



OMS (WHO)2021

***¿Qué tan lejos estamos del objetivo
ideal de salud?***

Guías anuales muy estrictas

(PM_{2.5}=5, PM₁₀=15, NO₂=10 µg/m³)

La mayoría de ciudades europeas las
superan rutinariamente.



Directiva UE 2008/50/EC

¿Se ha incumplido la ley?

Límites legalmente vinculantes en toda la UE
— mucho más permisivos que la OMS

(PM_{2.5}=25, NO₂=40 µg/m³).

Base de las alertas operativas.

Comparación Numérica — Mismo Contaminante, Tres Umbrales

Ejemplo con NO₂ — límite anual en µg/m³

Estándar	Umbral NO ₂	Naturaleza	Uso en la plataforma
EAQI / ICA	≤40 (Bueno)	Comunicativo	Banners de alerta, tarjetas de estación, badges de zona
OMS 2021	10 (límite anual)	Científico	Risk Score, líneas de referencia en gráficos
Directiva UE	40 (límite anual)	Legal	Alertas de Daily Briefing, Decision Support, informes PDF



Ejemplo concreto

Con PM2.5 = 12 µg/m³:
la OMS dice 2.4× el límite (preocupante a largo plazo),
la UE dice que está muy por debajo del límite legal (sin infracción),
el EAQI dice “Fairly good” (aceptable para hoy).
Las tres respuestas son correctas — responden preguntas distintas.

Dashboard Interactivo — 10 Páginas

Streamlit Cloud — actualizado automáticamente cada día

01

Resumen Diario

02

Monitoreo de Calidad del Aire

03

Tendencias Temporales

04

Análisis Espacial GeoAI

05

Factores Meteorológicos

06

Pronóstico (Forecasting)

07

Soporte a Decisiones

08

Metodología

09

Asistente del Proyecto (IA)

10

Operaciones (admin)

Conclusiones



La calidad de datos manda sobre la cantidad

Reducir de 10 a 7 estaciones y de 6 a 4 contaminantes garantizó series temporales completas — base indispensable para imputación MICE y modelos válidos.



El contexto espacial explica lo que el tiempo no puede

La paradoja de MUSKIZ demuestra que factores estructurales (terreno, distancia, viento) son tan importantes como la serie temporal.



Ningún estándar único cuenta toda la historia

EAQI, OMS y Directiva UE coexisten porque responden preguntas distintas — pública, científica y legal.



GeoAI

SMART CITY · AIR QUALITY

GRACIAS POR SU ATENCIÓN

¿Preguntas?

Demostración en vivo de la plataforma GeoAI a continuación



geoai-dashboard.streamlit.app

Arman Ghaziaskari Naeini · GIS & Spatial Data Scientist

<https://armanghazi.github.io/portfolio>